


2

西欧

2.21

缺水量 / 10^4 m^3



加勒比海地区

2.640

我国土地沙漠化问题非常严重，全国沙漠化土地总面积已超过 $1.74 \times 10^5 \text{ km}^2$ ，并以每年约为 $3.4 \times 10^3 \text{ km}^2$ 的速度扩张。

你知道这些数据是怎么来的吗？

第二章

统计

2.1 随机抽样

2.2 用样本估计总体

2.3 变量间的相关关系

我国是世界上的第
13个贫水国,人均淡水占有
量排列世界第109位。




我们生活在一个数字化时代,时刻都在与数据打交道,例如,产品的合格率、农作物的产量、商品的销售量、当地的气温、自然资源、就业状况、电视台的收视率,你知道这些数据是怎么来的吗?实际上它们是通过调查获得的,怎样调查呢?是对考察对象进行全面调查吗?例如,为了了解一批计算器的使用寿命,我们能将它们逐一测试吗?很明显,这既不可能,也没必要。实践中,由于所考察的总体中的个体数往往很多,而且许多考察带有破坏性,因此,我们通常只考察总体中的一个样本,通过样本来了解总体的情况。进一步,从节约费用的角度考虑,在保证样本估计总体达到一定精度的前提下,样本中包含的个体数越少越好。于是,如何设计抽样方法,使抽取的样本能够真正代表总体,就成为我们要关注的一个关键问题。否则,如果样本的代表性不好,那么对总体的判断就会出现错误。

那么,怎样从总体中抽取样本呢?如何表示样本数据呢?如何从样本数据中提取基本信息(样本分布、样本数字特征等),来推断总体的情况呢?这些正是本章要研究解决的问题。

CHAPTER 2

2.1



学段	城市	县镇	农村
小学	357 000	221 600	258 100
初中	226 200	154 200	112 900
高中	112 000	43 300	6 300

随机抽样

为什么说一个好的抽样调查胜过一次蹩脚的普查？

为了回答我们碰到的许多问题，必须收集相关数据。例如食品、饮料中的细菌是否超标，每天城市里的垃圾有多少被回收了，影响学生视力状况的主要原因有哪些，同学们的作息时间是如何安排的，电视台的某个栏目的收视率是多少，某厂产品的合格率是多少……这些问题都需要通过收集数据作出回答。

从节约费用等方面考虑，一般是从总体中收集部分个体的数据来得出结论，也就是要通过样本去推断总体。为此，我们首先必须清楚地知道要收集的数据是什么。例如，在食品质量检验中，为了了解某批袋装牛奶（总体）的细菌超标情况，从中随机地抽取了 n 袋，并测出了每一袋的细菌含量 a_i ($i=1, 2, \dots, n$)。这里， a_i ($i=1, 2, \dots, n$) 就是要收集的数据。其次，我们检查样本的目的是为了了解总体的情况。在上述牛奶质量检查中，我们的目的是要了解整批牛奶的细菌含量是否超标，而不是局限在抽查到的那些牛奶的细菌含量是否超标。因此，收集的样本数据应当能够很好地反映总体，这是从样本推断出关于总体的正确结论的前提。再次，我们要知道如何才能收集到高质量的样本数据。我们知道，为了判断一锅汤的味道如何，如果锅里的汤被充分搅拌了，那么我们只需品尝一勺就可以了。同样地，高质量的样本数据来自“搅拌均匀”的总体。如果我们能够设法将总体“搅拌均匀”，那么，从中任意抽取一部分个体的样本，它们含有与总体基本相同的信息。

总之，为了使样本具有好的代表性，设计抽样方法时，最重要的是要将总体“搅拌均匀”，即使每个个体有同样的机会被抽中。下面介绍的抽样方法都是以此作为出发点的。



一个著名的案例

在抽样调查中，样本的选择是至关重要的，样本能否代表总体，直接影响着统计结果的可靠性。下面的故事是一次著名的失败的统计调查，被称作抽样中的泰坦尼克事件，它可以帮助我们理解为什么一个好的样本如此重要。

在1936年美国总统选举前，一份颇有名气的杂志（Literary Digest）的工作人员做了一次民意测验。调查兰顿（A. Landon）（当时任堪萨斯州州长）和罗斯福（F. D. Roosevelt）（当时的总统）中谁将当选下一届总统。为了了解公众意向，调查者通过电话簿和车辆登记簿上的名单给一大批人发了调查表（注意在1936年电话和汽车只有少数富人拥有）。通过分析收回的调查表，显示兰顿非常受欢迎，于是此杂志预测兰顿将在选举中获胜。

实际选举结果正好相反，最后罗斯福在选举中获胜，其数据如下：

候选人	预测结果%	选举结果%
Roosevelt	43	62
Landon	57	38



像本例中这样容易得到的样本称为方便样本。
你认为预测结果出错的原因是什么？

2.1.1

简单随机抽样



假设你作为一名食品卫生工作人员，要对某食品店内的一批小包装饼干进行卫生达标检验。你准备怎样做？

显然，你只能从中抽取一定数量的饼干作为检验的样本。（为什么？）那么，应当怎样获取样本呢？

设计抽样方法时,在考虑样本的代表性的前提下,应当努力使抽样过程简便易行.

得到样本饼干的一个方法是,将这批小包装饼干放入一个不透明的袋子中,搅拌均匀,然后不放回地摸取(这样可以保证每一袋饼干被抽中的机会相等),这样我们就可以得到一个简单随机样本,相应的抽样方法就是简单随机抽样.

一般地,设一个总体含有 N 个个体,从中逐个不放回地抽取 n 个个体作为样本 ($n \leq N$),如果每次抽取时总体内的各个个体被抽到的机会都相等,就把这种抽样方法叫做**简单随机抽样** (simple random sampling).

最常用的简单随机抽样方法有两种——抽签法和随机数法.

(1) 抽签法 (抓阄法)

抽签法是大家最熟悉的,也许同学们在做某种游戏,或者选派一部分人参加某项活动时就用过抽签法.例如,高一(2)班有 45 名学生,现要从中抽出 8 名学生去参加一个座谈会,每名学生的机会均等.我们可以把 45 名学生的学号写在小纸片上,揉成小球,放到一个不透明袋子中,充分搅拌后,再从中逐个抽出 8 个号签,从而抽出 8 名参加座谈会的学生.

一般地,抽签法就是把总体中的 N 个个体编号,把号码写在号签上,将号签放在一个容器中,搅拌均匀后,每次从中抽取一个号签,连续抽取 n 次,就得到一个容量为 n 的样本.



你认为抽签法有什么优点和缺点?当总体中的个体数很多时,用抽签法方便吗?

抽签法简单易行,当总体中的个体数不多时,使总体处于“搅拌均匀”的状态比较容易,这时,每个个体有均等的机会被抽中,从而能够保证样本的代表性.但是,当总体中的个体数较多时,将总体“搅拌均匀”就比较困难,用抽签法产生的样本代表性差的可能性很大.

(2) 随机数法

随机抽样中, 另一个经常被采用的方法是随机数法, 即利用随机数表、随机数骰子或计算机产生的随机数进行抽样. 这里仅介绍随机数表法.

随机数表由数字 0, 1, 2, $\dots$, 9 组成, 并且每个数字在表中各个位置出现的机会都是一样的 (见附表).

怎样利用随机数表产生样本呢? 下面通过例子来说明.

假设我们要考察某公司生产的 500 克袋装牛奶的质量是否达标, 现从 800 袋牛奶中抽取 60 袋进行检验. 利用随机数表抽取样本时, 可以按照下面的步骤进行.

第一步, 先将 800 袋牛奶编号, 可以编为 000, 001, $\dots$, 799.

第二步, 在随机数表中任选一个数, 例如选出第 8 行第 7 列的数 7 (为了便于说明, 下面摘取了附表 1 的第 6 行至第 10 行).

16 22 77 94 39	49 54 43 54 82	17 37 93 23 78	87 35 20 96 43	84 26 34 91 64
84 42 17 53 31	57 24 55 06 88	77 04 74 47 67	21 76 33 50 25	83 92 12 06 76
63 01 63 78 59	16 95 55 67 19	98 10 50 71 75	12 86 73 58 07	44 39 52 38 79
33 21 12 34 29	78 64 56 07 82	52 42 07 44 38	15 51 00 13 42	99 66 02 79 54
57 60 86 32 44	09 47 27 96 54	49 17 46 09 62	90 52 84 77 27	08 02 73 43 28

第三步, 从选定的数 7 开始向右读 (读数的方向也可以是向左、向上、向下等), 得到一个三位数 785. 由于 $785 < 799$, 说明号码 785 在总体内, 将它取出; 继续向右读, 得到 916, 由于 $916 > 799$, 将它去掉, 按照这种方法继续向右读, 又取出 567, 199, 507, $\dots$, 依次下去, 直到样本的 60 个号码全部取出. 这样我们就得到一个容量为 60 的样本.

生产实践中, 往往是从一大批袋装牛奶中抽样, 也就是说总体中的个体数是很大的. 你能从这个例子出发说明一下抽样的必要性吗?

当 $N=100$ 时, 分别以 0, 3, 6 为起点对总体编号, 再利用随机数表抽取 10 个号码. 你能说出从 0 开始对总体编号的好处吗?

练习

1. 请你把抽样调查和普查做一个比较, 并说一说抽样调查的好处和可能出现的问题.
2. 假设要从高一年级全体同学 (450 人) 中随机抽出 50 人参加一项活动. 请分别用抽签法和随机数表法抽出人选, 写出抽取过程.
3. 请举出几个用抽签法或随机数表法抽取样本的实际例子. 你认为抽签法是如何保证样本的代表性的?
4. 你认为用随机数表法抽取样本有什么优点和缺点?

从上所述可知,简单随机抽样有操作简便易行的优点,在总体个数不多的情况下是行之有效的.但是,如果总体中的个体数很多时,对个体编号的工作量太大,即使使用随机数法操作也并不方便快捷.另外,要想“搅拌均匀”也非常困难,这就容易导致样本的代表性差.因此,为了操作上方便快捷,在不降低样本的代表性的前提下,可以采取下面的抽样方法.

2.1.2 系统抽样

探究

某学校为了了解高一年级学生对教师教学的意见,打算从高一年级 500 名学生中抽取 50 名进行调查.除了用简单随机抽样获取样本外,你能否设计其他抽取样本的方法?

请将这种抽样方法与简单随机抽样做一个比较,你认为这种抽样方法能提高样本的代表性吗?为什么?

我们按照这样的方法来抽样:首先将这 500 名学生从 1 开始进行编号,然后按号码顺序以一定的间隔进行抽取.由于 $\frac{500}{50} = 10$,这个间隔可以定为 10,即从号码为 1~10 的第一个间隔中随机地抽取一个号码,假如抽到的是 6 号,然后从第 6 号开始,每隔 10 个号码抽取一个,得到

6, 16, 26, 36, ..., 496.

这样我们就得到一个容量为 50 的样本.这种抽样方法是一种**系统抽样**(systematic sampling).

一般地,假设要从容量为 N 的总体中抽取容量为 n 的样本,我们可以按下列步骤进行系统抽样:

(1) 先将总体的 N 个个体编号.有时可直接利用个体自身所带的号码,如学号、准考证号、门牌号等;

(2) 确定分段间隔 k ,对编号进行分段.当 $\frac{N}{n}$ (n 是样本容量)是整数时,取 $k = \frac{N}{n}$;

(3) 在第 1 段用简单随机抽样确定第一个个体编号 l ($1 \leq l \leq k$);

如果遇到 $\frac{N}{n}$ 不是整数的情况,可以先从总体中随机地剔除几个个体,使得总体中剩余的个体数能被样本容量整除.

(4) 按照一定的规则抽取样本. 通常是将 l 加上间隔 k 得到第 2 个个体编号 $(l+k)$, 再加 k 得到第 3 个个体编号 $(l+2k)$, 依次进行下去, 直到获取整个样本.

练习

1. 你认为系统抽样有哪些优点和缺点?
2. 设某校共有 118 名教师, 为了支援西部的教育事业, 现要从中随机地抽出 16 名教师组成暑期西部讲师团. 请用系统抽样法选出讲师团成员.
3. 有人说, 我可以借用居民身份证号码来进行中央电视台春节联欢晚会的收视率调查: 在 1~999 中抽取一个随机数, 比如这个数是 632, 那么身份证后三位数是 632 的观众就是我要调查的对象. 请问, 这样所获得的样本有代表性吗? 为什么?



广告中数据的可靠性

今天已进入数字时代, 各种各样的统计数字和图表充斥着媒体, 由于数字给人的印象直观具体, 所以让数据说话是许多广告的常用手法. 但广告中的数据可靠吗?

在各类广告中, 你会经常遇到由“方便样本 (即样本没有代表性)”所产生的结论. 例如, 某减肥药的广告称, 其减肥的有效率为 75%. 见到这样的广告你会怎么想? 通过学习统计这部分内容, 你会提出下面的问题吗? 这个数据是如何得到的; 该药在多少人身上做过试验, 即样本容量是多少; 样本是如何选取的; 等等. 假设该药仅在 4 个人身上做过试验, 样本容量为 4, 用这样小的样本量来推断总体是不可信的.

“现代研究证明, 99% 以上的人感染有螨虫……”这是一家化妆品公司的广告. 第一次听到此话的人会下意识摸一下自己的皮肤, 甚至会感觉到有虫在里面蠕动, 恨不得立即弄些药膏抹抹, 广告的威慑作用不言而喻. 但这里 99% 是怎么得到的? 研究共检测了多少人? 这些人是如何挑选的? 如果检测的人都是去医院看皮肤病的人, 这个数据就不适用于一般人群.

某化妆品的广告声称: “它含有某种成分可以彻底地清除脸部皱纹, 只需 10 天, 就能让肌肤得到改善.” 我们看到的数字很精确, 而“能让肌肤得到改善”却是很模糊的. 这样的数字能相信吗? 试验是在什么样的皮肤上做的? 试验的人数是多少?

当我们见到广告中的数据时一定要多提几个问题.




请你从各种媒体中收集一些广告，并用统计的知识分析一下它们所提供的数据和结论的真实性。

我们知道，设计抽样方法时，最核心的问题是要考虑如何使抽取的样本具有好的代表性。为此，在设计抽样方法时，我们应考虑如何利用自己对总体的已有了解。例如，如果要调查某校高一学生的平均身高，由经验可知，男生一般要比女生高，这时就应采用另一种抽样方法——分层抽样。因为用简单抽样方法或系统抽样的方法都有可能产生绝大部分是男生（或女生）或全部都是男生（或女生）的样本，显然，这种样本是不能代表总体的。因此，设计抽样方法时，充分利用事先对总体情况的已有了解是非常重要的。

2.1.3 分层抽样



假设某地区有高中生2 400人，初中生10 900人，小学生11 000人，此地区教育部门为了了解本地区中小学生的近视情况及其形成原因，要从本地区的小中学生中抽取1%的学生进行调查。你认为应当怎样抽取样本？



你认为哪些因素可能影响学生的视力？设计抽样方法时需要考虑这些因素吗？

我们知道，影响学生视力的因素是非常复杂的。例如，不同年龄阶段的学生的近视情况可能存在明显差异。因此，宜将全体学生分成高中、初中和小学三部分分别抽样。另外，三个部分的学生人数相差较大，因此，为了提高样本的代表性，还应考虑他们在样本中所占比例的大小。

由于样本容量与总体中的个体数的比是1 : 100，因此，

样本中包含的各部分的个体数应该是

$$\frac{2\,400}{100}, \frac{10\,900}{100}, \frac{11\,000}{100},$$

即抽取 24 名高中生, 109 名初中生和 110 名小学生作为样本.

这样, 如果从学生人数这个角度来看, 按照这种抽样方法所获得的样本结构与这一地区全体中小学生的结构是基本相同的.

一般地, 在抽样时, 将总体分成互不交叉的层, 然后按照一定的比例, 从各层独立地抽取一定数量的个体, 将各层取出的个体合在一起作为样本, 这种抽样的方法就叫做**分层抽样** (stratified sampling).

从上面的抽样过程可以看出, 分层抽样尽量利用了调查者对调查对象 (总体) 事先所掌握的各种信息, 并充分考虑了保持样本结构与总体结构的一致性, 这对提高样本的代表性是非常重要的. 所以, 分层抽样在实际中有着非常广泛的应用. 通常, 当总体是由差异明显的几个部分组成时, 往往选用分层抽样的方法.

想一想, 为什么要这样取各个学段的个体数?

探究

(1) 简单随机抽样、系统抽样和分层抽样各有其特点和适用范围. 请对这三种抽样方法进行比较, 说说它们各自的优点和缺点.

(2) 某地区中小學生人数的分布情况如下表所示 (单位: 人):

学段	城市	县镇	农村
小学	357 000	221 600	258 100
初中	226 200	134 200	11 290
高中	112 000	43 300	6 300

请根据上述基本数据, 设计一个样本容量为总体中个体数量的千分之一的抽样方案.

在现实生活中, 由于资金、时间有限, 人力、物力不足, 再加上不断变化的环境条件, 做普查往往是不可能的. 因此, 我们一般是把数据的收集限制在总体的一个样本上. 由于总体的复杂性, 在实际抽样中, 为了使样本具有代表性, 通常要同时使用几种抽样方法. 例如, 在上述探究 (2)

中,我们可以先用分层抽样法确定出此地区城市、县镇、农村的被抽个体数,再用分层抽样法将城市的被抽个体数分配到小学、初中、高中等不同阶层中去,县镇、农村的被抽个体数的分配法也一样。接着,将城市划分为学生数大致相当的小区,用简单随机抽样法选取一些小区,再用简单随机抽样法确定每一小区中的各类学校。最后,在选中的学校中用系统抽样法或简单随机抽样法选取学生进行调查。

练习

1. 分别用简单随机抽样、系统抽样和分层抽样的方法,从全班同学中抽取 10 名同学,统计他们昨天户外活动的平均时间,全面调查全班同学昨天户外活动的平均时间,并与抽样统计的结果进行比较,你能发现什么问题?
2. 有人说:“如果抽样方法设计得好,用样本进行视力调查与对 24 300 名学生进行视力普查的结果会差不多,而且对于教育部门掌握学生视力状况来说,因为节省了人力、物力和财力,抽样调查更可取。”你认为这种说法有道理吗?为什么?
3. 一般来说,影响农作物收成的因素有气候、土质、田间管理水平等。如果你是一个农村调查队成员,要在麦收季节对你所在地区的小麦进行估产调查,你将如何设计调查方案?



如何得到敏感性问题的诚实反应

在统计调查中,问卷的设计是一门很大的学问。特别是对一些敏感性问题,例如学生在考试中有无作弊现象,社会上的偷税漏税等,更要精心设计问卷,设法消除被调查者的顾虑,使他们能够如实回答问题。否则,被调查者往往会拒绝回答,或不提供真实情况。下面我们用一个例子来说明对敏感性问题的调查方法。

某地区公共卫生部门为了调查本地区中学生的吸烟情况,对随机抽出的 200 名学生进行了调查。调查中使用了两个问题。

问题 1: 你的父亲阳历生日日期是不是奇数?

问题 2: 你是否经常吸烟?

调查者设计了一个随机化装置,这是一个装有大小、形状和质量完全一样的 50 个白球和 50 个红球的袋子。每个被调查者随机从袋中摸取 1 个球(摸出的球再放回袋中),摸到白球的学生如实回答第一个问题,摸到红球的学生如实回答第二个问题。回答“是”的人往一个盒子中放一个小石子,回答“否”的人什么都不要做。由于问题的答案只有

“是”和“否”，而且回答的是哪个问题也是别人不知道的，因此被调查者可以毫无顾虑地给出符合实际情况的答案。

请问：如果在 200 人中，共有 58 人回答“是”，你能估计出此地区中学生吸烟人数的百分比吗？

解：由题意可知，每个学生从口袋中摸出 1 个白球或红球的概率都是 0.5，即我们期望大约有 100 人回答了第一个问题，另 100 人回答了第二个问题。在摸出白球的情况下，回答父亲阳历生日日期是奇数的概率是 $\frac{186}{365} \approx 0.51$ 。因而在回答第一个问题的 100 人中，大约有 51 人回答了“是”，所以我们能推出，在回答第二个问题的 100 人中，大约有 7 人回答了“是”，即估计此地区大约有 7% 的中学生吸烟。

这种方法是不是很巧妙？



在问卷的设计中，不但要考虑“难以启齿”问题本身对调查结果的影响，而且还要考虑其他因素。例如，调查中问题的措辞会对被调查者产生影响，举例来说，“你在多大程度上喜欢吸烟”与“你在多大程度上不喜欢吸烟”两种问法中，前者会比后者给出更为肯定的答案。再如，问题在问卷中的位置也会对调查者产生影响。一般地，比较容易的、不涉及个人的问题应当排在比较靠前的位置，较难的、涉及个人的问题放在后面，等等。

请你设计一个关于青春问题的调查问卷。

习题 2.1

A 组

1. 在抽样过程中，如果总体中的每个个体都有相等的机会被抽中，那么我们就称这样产生的样本为随机样本。举例说明产生随机样本的困难。
2. 中央电视台希望在春节联欢晚会播出后一周内获得当年春节联欢晚会的收视率。下面是三名同学为电视台设计的调查方案。

同学 A：我把这张《春节联欢晚会收视率调查表》放在互联网上，只要上网登录该网址的人就可以看到这张表，他们填表的信息可以很快地反馈到我的电脑中。这样，我就可以很快

统计出收视率了。

同学 B: 我给我们居民小区的每一份住户发一个是否在除夕那天晚上看过中央电视台春节联欢的调查表, 只要一两天就可以统计出收视率。

同学 C: 我在电话号码本上随机地选出一定数量的电话号码, 然后逐个给他们打电话, 问一下他们是否收看了中央电视台春节联欢晚会, 我不出家门就可以统计出中央电视台春节联欢晚会的收视率。

请问: 上述三名同学设计的调查方案能够获得比较准确的收视率吗? 为什么?

3. 校学生会希望调查有关本学期学生活动计划的意见。你自愿担任调查员, 并打算在学校里抽取 10% 的同学作为样本。

(1) 你怎样安排抽样, 以保证样本的代表性?

(2) 在抽样中你可能遇到哪些问题?

(3) 这些问题可能会影响什么?

(4) 你打算怎样解决这些问题?

4. 请用简单随机抽样和系统抽样, 设计一个调查某地区一年内空气质量状况的方案, 哪一个方案更便于实施。

5. 一支田径队有男运动员 56 人, 女运动员 42 人, 用分层抽样的方法从全体运动员中抽出一个容量为 28 的样本。

6. 在一次游戏中, 获奖者可以得到 5 件不同的奖品, 这些奖品要从由 1~50 编号的 50 种不同奖品中随机抽取确定, 用系统抽样的方法为某位获奖者确定 5 件奖品的编号。

7. 设计一个抽样方案, 调查你们学校学生的近视率。

B 组

1. 你可能想了解许多问题, 比如, 全班同学比较喜欢哪门课程, 中学生每月的零花钱平均是多少, 喜欢看《新闻联播》的同学的比例是多少, 中学生每天大约什么时间起床, 每天睡眠的平均时间是多少等。选一些自己关心的问题, 设计一份调查问卷, 利用抽样的方法调查你们学校的学生情况, 并解释你所得到的结论。

2. 设计一个抽样方案, 调查中央电视台春节联欢晚会的收视率。

2.2


用样本估计总体

前面我们研究了通过抽样来收集数据的方法,了解了提高样本代表性的一些具体方法.数据被收集后,必须从中寻找所包含的信息,以使我们能通过样本估计总体.由于数据多而且杂乱,我们往往无法直接从原始数据中理解它们的含义.因此,必须通过图、表、计算来分析数据,帮助我们找出数据中的规律,使数据所包含的信息转化成直观的容易理解的形式.在此基础上,我们就可以对总体作出相应的估计.这种估计一般分成两种,一种是用样本的频率分布估计总体的分布,另一种是用样本的数字特征(如平均数、标准差等)估计总体的数字特征.

2.2.1 用样本的频率分布估计总体分布

探究

我国是世界上严重缺水的国家之一,城市缺水问题较为突出.某市政府为了节约生活用水,计划在本市试行居民生活用水定额管理,即确定一个居民月用水量标准 a ,用水量不超过 a 的部分按平价收费,超出 a 的部分按议价收费.如果希望大部分居民的日常生活不受影响,那么标准 a 定为多少比较合理呢?你认为,为了较为合理地确定出这个标准,需要做哪些工作?



2000年全国主要城市中
缺水情况排在前10位的城市

很明显,如果标准太高,会影响居民的日常生活;如果标准太低,则不利于节水.为了确定一个较为合理的标准 a ,必须先了解全市居民日常用水量的分布情况,比如月均用水量在哪个范围的居民最多,他们占全市居民的百分比情况等.

由于城市住户较多,通常采用抽样调查的方式,通过分析样本数据来估计全市居民用水量的分布情况.假设通过抽样,我们获得了100位居民某年的月均用水量(单位:t):

表 2-1 100 位居民的月均用水量 (单位: t)

3.1	2.5	2.0	2.0	1.5	1.0	1.6	1.8	1.9	1.6
3.4	2.6	2.2	2.2	1.5	1.2	0.2	0.4	0.3	0.4
3.2	2.7	2.3	2.1	1.6	1.2	3.7	1.5	0.5	3.8
3.3	2.8	2.3	2.2	1.7	1.3	3.6	1.7	0.6	4.1
3.2	2.9	2.4	2.3	1.8	1.4	3.5	1.9	0.8	4.3
3.0	2.9	2.4	2.4	1.9	1.3	1.4	1.8	0.7	2.0
2.5	2.8	2.3	2.3	1.8	1.3	1.3	1.6	0.9	2.3
2.6	2.7	2.4	2.1	1.7	1.4	1.2	1.5	0.5	2.4
2.5	2.6	2.3	2.1	1.6	1.0	1.0	1.7	0.8	2.4
2.8	2.5	2.2	2.0	1.5	1.0	1.2	1.8	0.6	2.2

实际抽样时,样本容量大小应当根据问题的需要来确定,并不一定样本容量越大越好.

一幅图胜过一千个字.看懂图是21世纪的成年人所必须具备的能力.

上面这些数字能告诉我们什么呢?很容易发现的是一个居民月均用水量的最小值是0.2 t,最大值是4.3 t,其他在0.2~4.3 t之间.除此之外,很难发现这100位居民的用水量的其他信息了.实际上,我们很难从随意记录下来的数据中直接看出规律.为此,我们需要对统计数据进行整理与分析.

分析数据的一种基本方法是用图将它们画出来,或者用紧凑的表格改变数据的排列方式.作图可以达到两个目的,一是从数据中提取信息,二是利用图形传递信息.表格则是通过改变数据的构成形式,为我们提供解释数据的新方式.

初中我们曾经学过频数分布图和频数分布表,这使我们能够清楚地知道数据分布在各个小组的个数.下面将要学习的频率分布表和频率分布图,则是从各个小组数据在样本容量中所占比例大小的角度,来表示数据分布的规律.它可以使我们看到整个样本数据的**频率分布**(frequency distribution)情况.具体的做法如下.

1. 求极差(即一组数据中最大值与最小值的差)

例如,

$$4.3 - 0.2 = 4.1,$$

说明样本数据的变化范围是4.1 t.

2. 决定组距与组数

组距与组数的确定没有固定的标准,常常需要一个尝试和选择的过程.将数据分组时,组数应力求合适,以使数据的分布规律能较清楚地呈现出来.组数太多或太少,都会影响我们了解数据的分布情况.数据分组的组数与样本容量有关,一般样本容量越大,所分组数越多.当样本容量不超过

100 时,按照数据的多少,常分成 5~12 组。

为方便起见,组距的选择应力求“取整”。在本问题中,如果取组距为 0.5 (t),那么

$$\text{组数} = \frac{\text{极差}}{\text{组距}} = \frac{4.1}{0.5} = 8.2,$$

因此可以将数据分为 9 组,这个组数是较合适的,于是取组距为 0.5,组数为 9。

3. 将数据分组

以组距为 0.5 将数据分组时,可以分成以下 9 组:

$$[0, 0.5), [0.5, 1), \dots, [4, 4.5).$$

4. 列频率分布表

计算各小组的频率,作出下面的**频率分布表**。

表 2-2 100 位居民月均用水量的频率分布表

分组	频数累计	频数	频率
[0, 0.5)	正	4	0.04
[0.5, 1)	正下	8	0.08
[1, 1.5)	正正正	15	0.15
[1.5, 2)	正正正正正	22	0.22
[2, 2.5)	正正正正正	25	0.25
[2.5, 3)	正正正	14	0.14
[3, 3.5)	正	6	0.06
[3.5, 4)	正	4	0.04
[4, 4.5)	丁	2	0.02
合计		100	1.00

表 2-2 的最后一列是各小组的频率,例如第一小组的频率是:

$$\frac{\text{第一组频数}}{\text{样本容量}} = \frac{4}{100} = 0.04.$$

5. 画频率分布直方图

根据表 2-2 可以得到如图 2.2-1 所示的**频率分布直方图**。




图 2.2-1

用计算机中的 Excel 软件很容易作出频率分布直方图,有条件的同学可以试一试。

图形有“好”与“坏”之分,如果复杂的思想能够在图中清晰、准确、有效地表达出来,那么就是一幅好图。

图 2.2-1 中,横轴表示月均用水量,纵轴表示频率/组距.由于

$$\text{小长方形的面积} = \text{组距} \times \frac{\text{频率}}{\text{组距}} = \text{频率},$$

所以各小长方形的面积表示相应各组的频率.这样,频率分布直方图就以面积的形式反映了数据落在各个小组的频率的大小.

容易知道,在频率分布直方图中,各小长方形的面积的总和等于 1.



同样一组数据,如果组距不同,横轴、纵轴的单位不同,得到的图的形状也会不同.不同的形状给人以不同的印象,这种印象有时会影响我们对总体的判断.分别以 0.1 和 1 为组距重新作图,然后谈谈你对图的印象.

现实中,许多数据的分布都是单峰而且对称的,如身高、体重、考试成绩、农作物产量、某种特定型产品的各种质量指标、股票价格等.请查阅资料做进一步了解.

表 2-2 和图 2.2-1 显示了样本数据落在各个小组的比例大小.从中我们可以看到,月均用水量在区间 $[2, 2.5)$ 内的居民最多,在 $[1.5, 2)$ 内的次之,大部分居民的月均用水量都在 $[1, 3)$ 之间.

直方图能够很容易地表示大量数据,非常直观地表明分布的形状,使我们能够看到在分布表中看不清楚的数据模式.例如,从图 2.2-1 可以清楚地看到,居民月均用水量的分布是“山峰”状的,而且是“单峰”的,另外还有一定的对称性,这说明,大部分居民的月均用水量集中在一个中间值附近,只有少数居民的月均用水量很多或很少.但是,直方图也丢失了一些信息,例如,原始数据不能在图中表示出来.

根据样本数据的频率分布,我们就可以推测这一城市全体居民月均用水量分布的大致情况.也就是根据样本的频率分布,我们可以大致估计出总体的分布.因为这种估计是以一定的统计调查为依据的,所以据此给市政府提出每位居民月用水量标准的建议,就具有较强的说服力了.



如果当地政府希望使 85% 以上的居民每月的用水量不超出标准, 根据频率分布表 2-2 和频率分布直方图 2.2-1, 你能对制定月用水量标准提出建议吗?

由表 2-2 和图 2.2-1 可以看出, 月用水量在 3 t 以上的居民所占的比例为 $6\% + 4\% + 2\% = 12\%$, 即大约有 12% 的居民月用水量在 3 t 以上, 88% 的居民月用水量在 3 t 以下. 因此, 居民月用水量标准定为 3 t 是一个可以考虑的标准.

想一想, 你认为 3 t 这个标准一定能够保证 85% 以上的居民用水不超标吗? 如果不一定, 那么哪些环节可能会导致结论的差别?

实际上, 这个标准还可能出现偏差. 所以, 在实践中, 对统计结论是需要进行评价的.

类似于频数分布折线图, 连接频率分布直方图中各小长方形上端的中点, 就得到**频率分布折线图** (图 2.2-2).




图 2.2-2

获得总体密度曲线的过程与我们在函数中学过的建立实际问题的函数模型 (如药物在人体内的残留量的变化曲线) 过程是相似的.

一般地, 当总体中的个体数较多时, 抽样时样本容量就不能太小. 例如, 如果要抽样调查一个省乃至全国的居民的月均用水量, 那么样本容量就应比调查一个城市的时候大. 可以想像, 随着样本容量的增加, 作图时所分的组数也在增加, 相应的频率折线图会越来越接近于一条光滑曲线, 统计中称这条光滑曲线为**总体密度曲线**, 如图 2.2-3 所示. 总体密度曲线反映了总体在各个范围内取值的百分比, 它能给我们提供更加精细的信息. 例如, 图中有阴影部分的面积, 就是总体在区间 (a, b) 内取值的百分比.

值得注意的是，总体密度曲线通常都是根据样本的频率分布估计出来的。




图 2.2-3



1. 对于任何一个总体，它的密度曲线是不是一定存在？为什么？
2. 对于任何一个总体，它的密度曲线是否可以被非常准确地画出来？为什么？

实际上，尽管有些总体密度曲线是客观存在的，但一般很难像函数图象那样被准确地画出来，我们只能用样本的频率分布对它进行估计。一般来说，样本容量越大，这种估计就越精确。

除了上面几种图、表能帮助我们理解样本数据外，统计中还有一种被用来表示数据的图叫做**茎叶图** (stem-and-leaf display)，我们结合下面的例子来说明作茎叶图的方法，以及从茎叶图中提取样本数据信息的方法。

某赛季甲、乙两名篮球运动员每场比赛得分的原始记录如下：

甲运动员得分：13，51，23，8，26，38，16，33，14，28，39；

乙运动员得分：49，24，12，31，50，31，44，36，15，37，25，36，39。

用茎叶图表示，如图 2.2-4。顾名思义，茎是指中间的一列数，叶就是从茎的旁边生长出来的数，中间的数字表示得分的十位数，旁边的数字分别表示两个人得分的个位数。

从图 2.2-4 可以看出，茎叶图不仅能够保留原始数据，而且能够展示数据的分布情况。比如，乙运动员的得分基本上是对称的，中位数是 36；甲运动员的得分除一个特殊得

甲				乙		
		8	0			
4	6	3	1	2	5	
3	6	8	2	5	4	
3	8	9	3	1	6	1 6 7 9
			4	4	9	
		1	5	0		

图 2.2-4

分(51分)外,也大致对称,中位数是26.由此可以清楚地看出,乙运动员的发挥比较稳定,总体得分情况比甲好.

在样本数据较少时,用茎叶图表示数据的效果较好.它不但可以保留所有信息,而且可以随时记录,这对数据的记录和表示都能带来方便.但当样本数据较多时,茎叶图就显得不太方便了.因为每一个数据都要在图中占据一个空间,如果数据很多,枝叶就会很长了.

练习

练习一 练习二 练习三

1. 从一种零件中抽取了80件,尺寸数据表示如下(单位:cm):

362.51×1	362.62×2	362.72×2	362.83×3
362.93×3	363.03×3	363.15×5	363.26×6
363.38×8	363.49×9	363.59×9	363.67×7
363.76×6	363.84×4	363.93×3	364.03×3
364.12×2	364.22×2	364.31×1	364.41×1

这里用 $x \times n$ 表示有 n 件尺寸为 x 的零件,如 362.51×1 表示有1件尺寸为 362.51 cm 的零件.

- 作出样本的频率分布表和频率分布直方图;
 - 在频率分布直方图中画出频率分布折线图.
2. 请班上的每个同学估计一下自己每天的课外学习时间(单位:min),然后作出课外学习时间的频率分布直方图.你认为能否由这个频率分布直方图估计出你们学校的学生课外学习时间的分布情况?可以用它来估计该地区的学生课外学习时间的分布情况吗?为什么?
3. 下面一组数据是某生产车间30名工人某日加工零件的个数,请设计适当的茎叶图表示这组数据,并由图出发说明一下这个车间此日的生产情况.

134	112	117	126	128	124	122	116	113	107
116	132	127	128	126	121	120	118	108	110
133	130	124	116	117	123	122	120	112	112

2.2.2 用样本的数字特征估计总体的数字特征

上一节我们学习了用图、表来组织样本数据，并且学习了如何通过图、表所提供的信息，用样本的频率分布估计总体的分布。为了从整体上更好地把握总体的规律，我们还需要通过样本的数据对总体的数字特征进行研究。



- (1) 怎样将各个样本数据汇总为一个数值，并使它成为样本数据的“中心点”？
- (2) 能否用一个数值来描写样本数据的离散程度？

1. 众数、中位数、平均数

初中我们曾经学过众数、中位数、平均数等各种数字特征。应当说，这些数字都能够为我们提供关于样本数据的特征信息。例如，在上一节调查 100 位居民的月均用水量的问题中，从这些样本数据的频率分布直方图可以看出，月均用水量的众数是 2.25 t（最高的矩形的中点）（如图 2.2-5），它告诉我们，该市的月均用水量为 2.25 t 的居民数比月均用水量为其他值的居民数多，但它并没有告诉我们多多少。




图 2.2-5

那么，如何从频率分布直方图中估计中位数呢？在样本中，有 50% 的个体小于或等于中位数，也有 50% 的个体大

于或等于中位数. 因此, 在频率分布直方图中, 中位数左边和右边的直方图的面积应该相等, 由此可以估计中位数的值. 图 2.2-6 中的虚线代表居民月均用水量的中位数的估计值, 其左边的直方图的面积代表着 50 个单位, 右边的直方图也是 50 个单位. 虚线处的数据值为 2.03.

思考?

2.03 这个中位数的估计值, 与样本的中位数值 2.0 不一样, 你能解释其中的原因吗?




图 2.2-6




图 2.2-7

图 2.2-6 显示, 大部分居民的月均用水量在中部 (2.03 t 左右), 但也有少数居民的月均用水量特别高. 显然, 对这部分居民的用水作出限制是非常合理的.

思考?

中位数不受少数几个极端值的影响, 这在某些情况下是一个优点, 但它对极端值的不敏感有时也会成为缺点. 你能举例说明吗?

图 2.2-7 显示了居民月均用水量的平均数 ($\bar{x}=1.973$), 它是频率分布直方图的“重心”. 由于平均数与每一个样本数据有关, 所以, 任何一个样本数据的改变都会引起平均数的改变. 这是中位数、众数都不具有的性质. 也正因为这个原因, 与众数、中位数比较起来, 平均数可以反映出更多的关于样本数据整体的信息. 从图 2.2-7 可以看出, 用水量最多的几个居民对平均数影响较大, 这是因为他们的月均用水量与平均数相差太多了.

探究

“用数据说话”，这是我们经常可以听到的一句话。但是，数据有时也会被利用，从而产生误导。例如，一个企业中，绝大多数是一线工人，他们的年收入可能是一万元左右，另有一些经理层次的人，年收入可以达到几十万元。这时，年收入的平均数会比中位数大得多。尽管这时中位数比平均数更合理些，但是这个企业的老板到人力市场去招聘工人时，也许更可能用平均数来回答有关工资待遇方面的提问。

你认为“我们单位的收入水平比别的单位高”这句话应当怎么解释？

练习

假设你是一名交通部门的工作人员，你打算向市长报告国家对本市 26 个公路项目投资的平均资金数额，其中一条新公路的建设投资为 2 200 万元人民币，另外 25 个项目的投资是 20 ~ 100 万元。中位数是 25 万元，平均数是 100 万元，众数是 20 万元。你会选择哪一种数字特征来表示国家对每一个项目投资的平均金额？你选择这种数字特征的缺点是什么？

2. 标准差

平均数向我们提供了样本数据的重要信息，但是，平均数有时也会使我们作出对总体的片面判断。某地区的统计报表显示，此地区的年平均家庭收入是 10 万元，给人的印象是这个地区的家庭收入普遍较高。但是，如果这个平均数是从 200 户贫困家庭和 20 户极富有的家庭收入计算出来的，那么，它就既不能代表贫困户家庭的年收入，也不能代表极富有家庭的年收入。因为这个平均数掩盖了一些极端的情况，而这些极端情况显然是不能忽视的。因此，只有平均数还难以概括样本数据的实际状态。

又如，有两位射击运动员在一次射击测试中各射靶 10 次，每次命中的环数如下：

甲 7 8 7 9 5 4 9 10 7 4
乙 9 5 7 8 7 6 8 6 7 7

如果你是教练，你应当如何对这次射击情况作出评价？如果这是一次选拔性考核，你应当如何作出选择？

如果看两人本次射击的平均成绩, 由于

$$\bar{x}_{\text{甲}} = 7, \quad \bar{x}_{\text{乙}} = 7,$$

两人射击的平均成绩是一样的. 那么, 是否两个人的水平就没有什么差异呢?




图 2.2-8

直观上看, 还是有差异的. 例如, 甲成绩比较分散, 乙的成绩相对集中 (如图 2.2-8 所示). 因此, 我们还需要从另外的角度来考察这两组数据. 例如, 在作统计图、表时提到过的极差

$$\text{甲的环数极差} = 10 - 4 = 6,$$

$$\text{乙的环数极差} = 9 - 5 = 4,$$

它们在一定程度上表明了样本数据的分散程度, 与平均数一起, 可以给我们许多关于样本数据的信息. 显然, 极差对极端值非常敏感, 注意到这一点, 我们可以得到一种“去掉一个最高分, 去掉一个最低分”的统计策略.

考察样本数据的分散程度的大小, 最常用的统计量是**标准差** (standard deviation). 标准差是样本数据到平均数的一种平均距离, 一般用 s 表示.

所谓“平均距离”, 其含义可作如下理解:

假设样本数据是 $x_1, x_2, \dots, x_n$, $\bar{x}$ 表示这组数据的平均数, x_i 到 $\bar{x}$ 的距离是

$$|x_i - \bar{x}| \quad (i=1, 2, \dots, n).$$

于是, 样本数据 $x_1, x_2, \dots, x_n$ 到 $\bar{x}$ 的“平均距离”是

$$S = \frac{|x_1 - \bar{x}| + |x_2 - \bar{x}| + \dots + |x_n - \bar{x}|}{n}.$$

由于上式含有绝对值, 运算不太方便, 因此, 通常改用如下公式来计算标准差

$$s = \sqrt{\frac{1}{n} [(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2]}.$$

标准差这个词有点儿奇怪, 既是标准的又是有偏差的东西到底是什么呢? 随着学习的深入, 相信你对它会有越来越深刻的理解.

在一般计算器中, 均设有计算标准差的按键. 在求一组数据的标准差时, 只要让计算器处于统计状态, 将数据逐个输入, 然后按标准差的键, 即可立即显示所求标准差的值.

一个样本中的个体与平均数之间的距离关系可用下图表示：

考虑一个容量为 2 的样本： $x_1 < x_2$ ，其样本的标准差为

$$\frac{x_2 - x_1}{2}, \text{ 记 } a = \frac{x_2 - x_1}{2}.$$




图 2.2-9

显然，标准差越大，则 a 越大，数据的离散程度越大；标准差越小，数据的离散程度越小。

用计算器计算运动员甲的成绩的标准差的过程如下：

MODE **2** (进入统计计算模式)

SHIFT **CLR** **1** **=** (清除统计存储器)

7 **DT** **8** **DT** **7** **DT** **9** **DT** **5** **DT**

4 **DT** **9** **DT** **10** **DT** **7** **DT** **4** **DT**

SHIFT **S-VAR** **2** **=** (计算样本标准差)

2

即 $s_{\text{甲}} = 2$ 。

用类似的方法，可得 $s_Z \approx 1.095$ 。

由 $s_{\text{甲}} > s_Z$ 可以知道，甲的成绩离散程度大，乙的成绩离散程度小。由此可以估计，乙比甲的射击成绩稳定。

上面两组数据的离散程度与标准差之间的关系可用图 2.2-10 直观地表示出来。




图 2.2-10

标准差的取值范围是什么？标准差为 0 的样本数据有什么特点？

不同计算器的参数可能不同，例如有的计算器的统计模式为“MODE 1”，计算样本标准差的参数为 3。

例 1 画出下列四组样本数据的直方图, 说明它们的异同点.

(1) 5, 5, 5, 5, 5, 5, 5, 5, 5;

(2) 4, 4, 4, 5, 5, 5, 6, 6, 6;

(3) 3, 3, 4, 4, 5, 6, 6, 7, 7;

(4) 2, 2, 2, 2, 5, 8, 8, 8, 8.

解: 四组样本数据的直方图是:




图 2.2-11

四组数据的平均数都是 5.0, 标准差分别是 0.00, 0.82, 1.49, 2.83. 虽然它们有相同的平均数, 但是它们有不同的标准差, 说明数据的分散程度是不一样的.

标准差还可以用于对样本数据的另外一种解释. 例如, 在关于居民月均用水量的例子中, 平均数 $\bar{x}=1.973$, 标准差 $s=0.868$, 所以

$$\bar{x}+s=2.841, \quad \bar{x}+2s=3.709;$$

$$\bar{x}-s=1.105, \quad \bar{x}-2s=0.237.$$

这 100 个数据中, 在区间 $[\bar{x}-2s, \bar{x}+2s]=[0.237, 3.709]$ 外的只有 4 个, 也就是说, $[\bar{x}-2s, \bar{x}+2s]$ 几乎包含了所有样本数据.

从数学的角度考虑, 人们有时用标准差的平方 s^2 ——**方差**来代替标准差, 作为测量样本数据分散程度的工具:

$$s^2 = \frac{1}{n} [(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \cdots + (x_n - \bar{x})^2].$$

显然, 在刻画样本数据的分散程度上, 方差与标准差是一样的. 但在解决实际问题时, 一般多采用标准差.

需要指出的是, 现实中的总体所包含的个体数往往是很多的, 总体的平均数与标准差是不知道的. 如何求得总体的平均数和标准差呢? 通常的做法是用样本的平均数和标准差去估计总体的平均数与标准差. 这与前面用样本的频率分布来近似地代替总体分布是类似的. 只要样本的代表性好, 这样做就是合理的, 也是可以接受的.

例 2 甲乙两人同时生产内径为 25.40 mm 的一种零件. 为了对两人的生产质量进行评比, 从他们生产的零件中各抽出 20 件, 量得其内径尺寸如下 (单位: mm):

甲

25.46	25.32	25.45	25.39	25.36
25.34	25.42	25.45	25.38	25.42
25.39	25.43	25.39	25.40	25.44
25.40	25.42	25.35	25.41	25.39

乙

25.40	25.43	25.44	25.48	25.48
25.47	25.49	25.49	25.36	25.34
25.33	25.43	25.43	25.32	25.47
25.31	25.32	25.32	25.32	25.48

从生产的零件内径的尺寸看, 谁生产的质量较高?

为什么说“两个总体的平均数与标准差都是不知道的”？
25.40 mm为什么不是它们的平均数？

如果一个总体包含6个个体，现在要从中抽出3个作为样本，请你列出所有可能的样本。

假如以你班全体同学的身高作为总体，现从中抽出20名同学的身高组成样本，想像一下可能有多少个不同的样本？

分析：每一个工人生产的所有零件的内径尺寸组成一个总体。由于零件的生产标准已经给出（内径 25.40 mm），生产质量可以从总体的平均数与标准差两个角度来衡量。总体的平均数与内径标准尺寸 25.40 mm 的差异大时质量低，差异小时质量高；当总体的平均数与标准尺寸很接近时，总体的标准差小的时候质量高，标准差大的时候质量低。这样，比较两人的生产质量，只要比较他们所生产的零件内径尺寸所组成的两个总体的平均数与标准差的大小即可。但是，这两个总体的平均数与标准差都是不知道的，根据用样本估计总体的思想，我们可以通过抽样分别获得相应的样本数据，然后比较这两个样本的平均数、标准差，以此作为两个总体之间差异的估计值。

解：用计算器计算可得

$$\bar{x}_甲 = 25.4005, \quad \bar{x}_乙 = 25.4008;$$

$$s_甲 = 0.038, \quad s_乙 = 0.074.$$

从样本平均数看，甲生产的零件内径比乙的更接近内径标准(25.40 mm)，但是差异很小；从样本标准差看，由于 $s_甲 < s_乙$ ，因此甲生产的零件内径比乙的稳定程度高得多。于是，可以作出判断，甲生产的零件的质量比乙的高一些。

从上述例子我们可以看到，对一名工人生产的零件内径（总体）的质量判断，与所抽取的零件内径（样本数据）直接相关。显然，我们可以从这名工人生产的零件中获取许多样本（为什么？）。这样，尽管总体是同一个，但由于样本不同，相应的样本频率分布与平均数、标准差等都会发生改变，这就会影响到我们对总体情况的估计。如果样本的代表性差，那么对总体所作出的估计就会产生偏差；样本没有代表性时，对总体作出错误估计的可能性就非常大。这也正是我们在前面讲随机抽样时反复强调样本代表性的理由。在实际操作中，为了减少错误的发生，条件许可时，通常采取适当增加样本容量的方法。当然，关键还是要改进抽样方法，提高样本的代表性。

练习

1. 农场种植的甲乙两种水稻, 在面积相等的两块稻田中连续 6 年的年平均产量如下(单位: 500 g):

品种	第 1 年	第 2 年	第 3 年	第 4 年	第 5 年	第 6 年
甲	900	920	900	850	910	920
乙	890	960	950	850	860	890

哪种水稻的产量比较稳定?

2. 一个小商店从一家食品有限公司购进 21 袋白糖, 每袋白糖的标准重量是 500 g, 为了了解这些白糖的重量情况, 称出各袋白糖的重量(单位: g) 如下:

486	495	496	498	499	493	493
498	484	497	504	489	495	503
499	503	509	498	487	500	508

求:

- (1) 21 袋白糖的平均重量 $\bar{x}$ 是多少? 标准差 s 是多少?
 (2) 重量位于 $\bar{x}-s$ 与 $\bar{x}+s$ 之间有多少袋白糖? 所占的百分比是多少?

3. 下列数据是 30 个不同国家中每 100 000 名男性患某种疾病的死亡率:

27.0	23.9	41.6	33.1	40.6	18.8	13.7	28.9	13.2	14.5
27.0	34.8	28.9	3.2	50.1	5.6	8.7	15.2	7.1	5.2
16.5	13.8	19.2	11.2	15.7	10.0	5.6	1.5	33.8	9.2

- (1) 作出这些数据分布的频率分布直方图;
 (2) 请由这些数据计算平均数、中位数和标准差, 并对它们的含义进行解释.



生产过程中的质量控制图

我们知道, 平均数 μ 表明了总体的重心所在, 标准差 σ 表明了总体的离散程度. 但是, 当我们从样本数据中计算出这两个数值后, 其他信息就丢失了. 所以, 这两个数值并不能刻画总体的全貌. 不过, 现实生活中, 有一些总体(如某地区同龄儿童的身高、体重等)的分布的密度曲线是由它的平均数 μ 与标准差 σ 完全确定的(图 1~图 3), 我们把这种分布记作 $N(\mu, \sigma^2)$, 称为平均数为 μ , 方差为 σ^2 的正态分布.



从密度曲线图可以测量出这个总体在 $(\mu-\sigma, \mu+\sigma)$ $(\mu-2\sigma, \mu+2\sigma)$ 和 $(\mu-3\sigma, \mu+3\sigma)$ 等区间内取值的百分比是：

区 间	取值的百分比
$(\mu-\sigma, \mu+\sigma)$	68.3%
$(\mu-2\sigma, \mu+2\sigma)$	95.4%
$(\mu-3\sigma, \mu+3\sigma)$	99.7%

上述总体分布在产品质量控制中的应用是非常广泛的。例如，工人生产零件时，零件尺寸一般服从 $N(\mu, \sigma^2)$ 分布。这样，零件尺寸在 $(\mu-3\sigma, \mu+3\sigma)$ 以外取值的只有0.3%，它表明在大量重复试验中，平均每抽取1 000个零件，属于这个范围以外的尺寸大约有3个。因此在一批产品中随机抽取一个零件，零件尺寸在 $(\mu-3\sigma, \mu+3\sigma)$ 以外是几乎不可能发生的。一旦这种情况发生，即零件尺寸 x 满足 $|x-\mu| \geq 3\sigma$ ，我们就有理由认为生产中可能出现了异常情况。比如，可能原料、机器出了问题，或工艺规程不完善，或工人操作时精力不集中等。这种情况下，需要停机检查，找出原因，使生产过程重新控制在一种正常状态，从而避免继续生产更多的次品，以保证产品质量。




图 4

这就是运用统计原理进行产品质量控制的基本思想。目前，在生产中广泛运用的质量控制图（图4），就是根据上述原理制作的。

图4实际上是将图3旋转90°后得到的。在生产过程中，从某一时刻起，每隔一定时间任取一个零件进行检查，将其尺寸用圆点在图中表示出来，如果圆点在控制界限以内，

可认为生产情况正常；如果圆点超出控制界限，可认为有异常情况发生，应该停机检查。

至此，你对标准差的含义是否有了进一步的理解？请你根据上述阅读材料谈谈你对标准差的认识。

习题 2.2

A 组

1. 有一种鱼的身体吸收汞，汞的含量超过体重的 1.00 ppm（即百万分之一）时就会对人体产生危害。在 30 条鱼的样本中发现的汞含量是：

0.07 0.24 0.95 0.98 1.02 0.98 1.37 1.40 0.39 1.02
1.44 1.58 0.54 1.08 0.61 0.72 1.20 1.14 1.62 1.68
1.85 1.20 0.81 0.82 0.84 1.29 1.26 2.10 0.91 1.31

- (1) 用前两位数作为茎，画出样本数据的茎叶图；
- (2) 描述一下汞含量的分布特点；
- (3) 从实际情况看，许多鱼的汞含量超标在于有些鱼在出售之前没有被检查过。每批这种鱼的平均汞含量都比 1.00 ppm 大吗？
- (4) 求出上述样本数据的平均数和标准差；
- (5) 有多少条鱼的汞含量在平均数与 2 倍标准差的和（差）的范围内？

2. 在一批棉花中抽测了 60 根棉花的纤维长度，结果如下（单位：mm）：

82	202	352	321	25	293	293	86	28	206
323	355	357	33	325	113	233	294	50	296
115	236	357	326	52	301	140	328	238	358
58	255	143	360	340	302	370	343	260	303
59	146	60	263	170	305	380	346	61	305
175	348	264	383	62	306	195	350	265	385

作出这个样本的频率分布直方图（在对样本数据分组时，可试用几种不同的分组方式，然后从中选择一种较为合适的分组方法）。棉花的纤维长度是棉花质量的重要指标，你能从图中分析出这批棉花的质量状况吗？

3. 以往的招生统计数据显示，某所大学录取的新生高考总分的中位数基本上稳定在 550 分。你的一位校友在今年的高考中得了 520 分，你是立即劝阻他报考这所大学，还是先查阅一下这所大学招生的其他信息？解释一下你的选择。

4. 在去年的足球甲 A 联赛上, 一队每场比赛平均失球数是 1.5, 全年比赛失球个数的标准差为 1.1; 二队每场比赛平均失球数是 2.1, 全年失球个数的标准差是 0.4. 你认为下列说法中哪一种是正确的, 为什么?
- (1) 平均说来一队比二队技术好;
 - (2) 二队比一队技术水平更稳定;
 - (3) 一队有时表现很差, 有时表现又非常好;
 - (4) 二队很少不失球.
5. 在一次人才招聘会上, 有一家公司的招聘员告诉你, “我们公司的收入水平很高” “去年, 在 50 名员工中, 最高年收入达到了 100 万, 他们年收入的平均数是 3.5 万”. 如果你希望获得年薪 2.5 万元,
- (1) 你是否能够判断自己可以成为此公司的一名高收入者?
 - (2) 如果招聘员继续告诉你, “员工收入的变化范围是从 0.5 万到 100 万”, 这个信息是否足以使你作出自己是否受聘的决定? 为什么?
 - (3) 如果招聘员继续给你提供了如下信息, 员工收入的中间 50% (即去掉最少的 25% 和最多的 25% 后所剩下的) 的变化范围是 1 万到 3 万, 你又该如何使用这条信息来作出是否受聘的决定?
 - (4) 你能估计出收入的中位数是多少吗? 为什么均值比估计出的中位数高很多?
6. 甲乙两台机床同时生产一种零件, 10 天中, 两台机床每天出的次品数分别是:

甲 0 1 0 2 2 0 3 1 2 4

乙 2 3 1 1 0 2 1 1 0 1

分别计算这两组数据的平均数与标准差. 从计算结果看, 哪台机床的性能较好?

7. 有 20 种不同的零食, 它们的热量含量如下:

110	120	123	165	432	190	174	235	428	318
249	280	162	146	210	120	123	120	150	140

- (1) 以上述 20 个数据组成总体, 求总体平均数与总体标准差.
- (2) 设计恰当的随机抽样方法, 从总体中抽取一个容量为 7 的样本, 求样本的平均数与标准差.
- (3) 利用上面的抽样方法, 再抽取容量为 7 的样本, 计算样本的平均数和标准差. 这个样本的平均数与标准差和 (2) 中的结果一样吗? 为什么?
- (4) 利用 (2) 中的随机抽样方法, 分别从总体中抽取一个容量为 10、13、16、19 的样本, 求样本的平均数与标准差. 分析样本容量与样本平均数和样本标准差对总体的估计效果之间有什么关系.

B 组

1. 在训练运动员的过程中, 需要进行体能测试, 这种测试通常是由专业部门完成的. 下面的结果是由两个权威部门对 10 名游泳运动员进行测试后给出的.

测试	A	B	C	D	E	F	G	H	I	J
T_1	20	23	24	18	17	16	25	24	21	19
T_2	31	39	39	29	28	31	40	30	31	30

已经知道, 对全国样本, 测试 T_1 的平均数为 20, 标准差为 2; 测试 T_2 的平均数是 35, 标准差是 3.

- (1) 上述两个测试哪一个做得更好些?
 - (2) 如果你是教练, 为了增强你的队员的信心, 你应该选择哪个测试?
 - (3) 分值越高, 运动员的运动水平越高, 哪一名运动员最强? 哪一名运动员最弱?
2. 调查本班每位同学的家庭在同一周的用电量, 作出这组数据的频率分布表、频率分布直方图以及频率折线图, 对你所在地区的用电量情况进行估计, 然后在全班进行讨论.

CHAPTER 2.3

变量间的相关关系

2.3.1 变量之间的相关关系



在学校里，老师对学生经常这样说：“如果你的数学成绩好，那么你的物理学习就不会有什么大问题。”按照这种说法，似乎学生的物理成绩与数学成绩之间存在着一种相关关系。这种说法有没有根据呢？

凭我们的学习经验可知，物理成绩确实与数学成绩有一定的关系，但除此以外，还存在其他影响物理成绩的因素。例如，是否喜欢物理，用在物理学习上的时间等等。当我们主要考虑数学成绩对物理成绩的影响时，就是要考察这两者之间的相关关系。

我们还可以举出现实生活中存在的许多相关关系的问题。例如：

1. 商品销售收入与广告支出经费之间的关系。商品销售收入与广告支出经费有着密切的联系，但商品销售收入不仅与广告支出多少有关，还与商品质量、居民收入等因素有关。

2. 粮食产量与施肥量之间的关系。在一定范围内，施肥量越大，粮食产量就越高。但是，施肥量并不是决定粮食产量的唯一因素，因为粮食产量还要受到土壤质量、降雨量、田间管理水平等因素的影响。

3. 人体内的脂肪含量与年龄之间的关系。在一定年龄段内，随着年龄的增长，人体内的脂肪含量会增加，但人体内的脂肪含量还与饮食习惯、体育锻炼等有关，可能还与个人的先天体质有关。

应当说，对于上述各种问题中的两个变量之间的相关关

系, 我们都可以根据自己的生活、学习经验作出相应的判断, 因为“经验当中有规律”. 但是, 不管你的经验多么丰富, 如果只凭经验办事, 还是很容易出错的. 因此, 在分析两个变量之间的相关关系时, 我们需要一些有说服力的方法.

在寻找变量之间相关关系的过程中, 统计同样发挥着非常重要的作用. 因为上面提到的这种关系, 并不像匀速直线运动中时间与路程的关系那样是完全确定的, 而是带有不确定性. 这就需要通过收集大量的数据 (有时通过调查, 有时通过实验), 在对数据进行统计分析的基础上, 发现其中的规律, 才能对它们之间的关系作出判断.

练习

1. 有关法律规定, 香烟盒上必须印上“吸烟有害健康”的警示语. 吸烟是否一定会引起健康问题? 你认为“健康问题不一定是由吸烟引起的, 所以可以吸烟”的说法对吗?
2. 某地区的环境条件适合天鹅栖息繁衍, 有人经统计发现了一个有趣的现象, 如果村庄附近栖息的天鹅多, 那么这个村庄的婴儿出生率也高, 天鹅少的地方婴儿的出生率低. 于是, 他就得出一个结论: 天鹅能够带来孩子. 你认为这样得到的结论可靠吗? 如何证明这个结论的可靠性?

2.3.2 两个变量的线性相关

探究

样本数据:

在一次对人体脂肪含量和年龄关系的研究中, 研究人员获得了一组

表 2-3 人体的脂肪百分比和年龄

年龄	23	27	39	41	45	49	50
脂肪	9.5	17.8	21.2	25.9	27.5	26.3	28.2
年龄	53	54	56	57	58	60	61
脂肪	29.6	30.2	31.4	30.8	33.5	35.2	34.6

根据上述数据, 人体的脂肪含量与年龄之间有怎样的关系?

一般地, 对于某个人来说, 他的体内脂肪不一定随年龄

增长而增加或减少。但是如果把很多个体放在一起,这时就可能表现出一定的规律性。各年龄对应的脂肪数据是这个年龄人群脂肪含量的样本平均数。观察表中数据,大体上来看,随着年龄的增加,人体中脂肪的百分比也在增加。为了确定这一关系的细节,我们需要进行数据分析。与以前一样,我们可以作统计图、表。通过作统计图、表,可以使我们对两个变量之间的关系有一个直观上的印象和判断。

下面要作的图叫做**散点图**(scatterplot)。对于表 2-3 中的数据,我们假设人的年龄影响体内脂肪含量,于是,按照习惯,以 x 轴表示年龄,以 y 轴表示脂肪含量,得到相应的散点图(图 2.3-1)。

计算机可以帮助我们作散点图。实际上,图 2.3-1 就是用计算机作出来的。




图 2.3-1

从散点图我们可以看出,年龄越大,体内脂肪含量越高。图中点的趋势表明两个变量之间确实存在一定的关系,这个图支持了我们从数据表中得出的结论。

另外,这些点散布的位置也是值得注意的,它们散布在从左下角到右上角的区域。对于两个变量的这种相关关系,我们将它称为**正相关**。还有一些变量,例如汽车的重量和汽车每消耗 1 L 汽油所行驶的平均路程,成**负相关**,汽车越重,每消耗 1 L 汽油所行驶的平均路程就越短,这时的点散布在从左上角到右下角的区域内。



- (1) 两个变量成负相关关系时,散点图有什么特点?
- (2) 你能举出一些生活中的变量成正相关或成负相关的例子吗?

接下来, 需要进一步考虑的问题是, 当人的年龄增加时, 体内脂肪含量到底是以什么方式增加的呢?




图 2.3-2

回归直线通过样本点的中心, 比照平均数与样本数据之间的关系, 你能说说回归直线与散点图中各点之间的关系吗?

从散点图上可以看出, 这些点大致分布在通过散点图中心的一条直线附近 (图 2.3-2). 如果散点图中点的分布从整体上看大致在一条直线附近, 我们就称这两个变量之间具有线性相关关系, 这条直线叫做**回归直线** (regression line). 如果能够求出这条回归直线的方程 (简称回归方程), 那么我们就可以比较清楚地了解年龄与体内脂肪含量的相关性. 就像平均数可以作为一个变量的数据的代表一样, 这条直线可以作为两个变量具有线性相关关系的代表.

那么, 我们应当如何具体求出这个回归方程呢?

有的同学可能会想, 我可以采用测量的方法, 先画出一条直线, 测量出各点与它的距离, 然后移动直线, 到达一个使距离的和最小的位置, 测量出此时的斜率和截距, 就可得到回归方程了 (图 2.3-3). 但是, 这样做可靠吗?

有的同学可能还会想, 在图中选择这样的两点画直线, 使得直线两侧的点的个数基本相同 (图 2.3-4). 同样地, 这样做能保证各点与此直线在整体上是最接近的吗?

还有的同学会想, 在散点图中多取几组点, 确定出几条直线的方程 (图 2.3-5), 再分别求出各条直线的斜率、截距的平均数, 将这两个平均数当成回归方程的斜率和截距.

同学们不妨去实践一下, 看看这些方法是不是真的可行?

“回归”这个词是由英国著名的统计学家 Francis Galton 提出来的。1889 年，他在研究祖先与后代身高之间的关系时发现，身材较高的父母，他们的孩子也较高，但这些孩子的平均身高并没有他们父母的平均身高高；身材较矮的父母，他们的孩子也较矮，但这些孩子的平均身高却比他们父母的平均身高高。Galton 把这种后代的身高向中间值靠近的趋势称为“回归现象”。后来，人们把由一个变量的变化去推测另一个变量的变化的方法称为**回归方法**。




图 2.3-3




图 2.3-4




图 2.3-5

上面这些方法虽然有一定的道理，但总让人感到可靠性不强。

实际上，求回归方程的关键是如何用数学的方法来刻画“从整体上看，各点与此直线的距离最小”。人们经过长期的

你能解释一下“从整体上看，各点与此直线的距离最小”的含义吗？

实践与研究，已经得出了计算回归方程的斜率与截距的一般公式

$$\begin{cases} b = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2}, \\ a = \bar{y} - b\bar{x}. \end{cases} \quad ①$$

其中， b 是回归方程的斜率， a 是截距。

推导公式①的计算比较复杂，这里不作推导。但是，我们可以解释一下得出它的原理。

假设我们已经得到两个具有线性相关关系的变量的一组数据

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n),$$

且所求回归方程是

$$\hat{y} = bx + a,$$

其中 a, b 是待定参数。当变量 x 取 x_i ($i=1, 2, \dots, n$) 时，可以得到

$$\hat{y}_i = bx_i + a \quad (i=1, 2, \dots, n),$$

它与实际收集到的 y_i 之间的偏差是 (图 2.3-6)

$$y_i - \hat{y}_i = y_i - (bx_i + a) \quad (i=1, 2, \dots, n).$$




图 2.3-6

这样，用这 n 个偏差的和来刻画“各点与此直线的整体偏差”是比较合适的。由于 $(y_i - \hat{y})$ 可正可负，为了避免相互抵消，可以考虑用 $\sum_{i=1}^n |y_i - \hat{y}_i|$ 来代替，但由于它含有绝对值，运算不太方便，所以改用

$$Q = (y_1 - bx_1 - a)^2 + (y_2 - bx_2 - a)^2 + \dots + (y_n - bx_n - a)^2 \quad ②$$

来刻画 n 个点与回归直线在整体上的偏差。

这样，问题就归结为：当 a, b 取什么值时 Q 最小，即

总体偏差最小, 经过数学上求最小值的运算, a, b 的值由公式①给出。

通过求②式的最小值而得出回归直线的方法, 即求回归直线, 使得样本数据的点到它的距离的平方和最小, 这一方法叫做**最小二乘法** (method of least square)。

根据最小二乘法的思想和公式①, 利用计算器或计算机, 可以方便地求出回归方程。

以 Excel 软件为例, 用散点图来建立表示人体的脂肪含量与年龄的相关关系的线性回归方程, 具体步骤如下:

(1) 在 Excel 中选定表示人体的脂肪含量与年龄的相关关系的散点图 (如图 2.3-1 所示), 在菜单中选定“图表”中的“添加趋势线”选项, 弹出“添加趋势线”对话框。

(2) 单击“类型”标签, 选定“趋势预测/回归分析类型”中的“线性”选项, 单击“确定”按钮, 得到回归直线。

(3) 双击回归直线, 弹出“趋势线格式”对话框, 单击“选项”标签, 选定“显示公式”, 最后单击“确定”按钮, 得到回归直线的回归方程 (图 2.3-7)

$$\hat{y} = 0.577x - 0.448.$$




图 2.3-7

用计算器求这个回归方程的过程如下:

MODE 3 1 (进入回归计算模式)

SHIFT CLR 1 = (清除统计存储器)

23	,	9.5	DT	27	,	17.8	DT
39	,	21.2	DT	41	,	25.9	DT
45	,	27.5	DT	49	,	26.3	DT
50	,	28.2	DT	53	,	29.6	DT
54	,	30.2	DT	56	,	31.4	DT
57	,	30.8	DT	58	,	33.5	DT
60	,	35.2	DT	61	,	34.6	DT

SHIFT S-VAR → → 1 = (计算参数 a)

-0.448

SHIFT S-VAR → → 2 = (计算参数 b)

0.577

所以回归方程为 $\hat{y} = 0.577x - 0.448$.

正像本节开头所说的,我们从人体脂肪含量与年龄这两个变量的一组随机样本数据中,找到了它们之间关系的一个规律,这个规律是由回归直线来反映的.



将表 2-3 中的年龄作为 x 代入上述回归方程,看看得出的数值与真实数值之间的关系,从中你体会到什么?

利用回归直线,我们可以进行预测.如果我们知道了某人的年龄,就可以利用回归方程来预测他的体内脂肪含量的百分比.例如,某人 37 岁,我们预测他的体内脂肪含量在 20.87% ($0.576 \times 37 - 0.446 = 20.87\%$) 附近的可能性比较大.不过,我们不能说他的体内脂肪含量一定是 20.87%.事实上,这个 20.87% 是对年龄为 37 岁的人群中

的大部分人的体内脂肪含量所作出的估计.

例 有一个同学家开了一个小卖部,他为了研究气温对热饮销售的影响,经过统计,得到一个卖出的热饮杯数与当天气温的对比表:

表 2-4

摄氏温度/ $^{\circ}\text{C}$	-5	0	4	7	12	15	19	23	27	31	36
热饮杯数	156	150	132	128	130	116	104	89	93	76	54

- (1) 画出散点图;
- (2) 从散点图中发现气温与热饮销售杯数之间关系的一般规律;
- (3) 求回归方程;
- (4) 如果某天的气温是 2°C , 预测这天卖出的热饮杯数.

解: (1) 散点图如图 2.3-8 所示:




图 2.3-8

(2) 从图 2.3-8 看到, 各点散布在从左上角到右下角的区域里, 因此, 气温与热饮销售杯数之间成负相关, 即气温越高, 卖出去的热饮杯数越少.

(3) 从散点图可以看出, 这些点大致分布在一条直线的附近, 因此, 可用公式①求出回归方程的系数.

利用计算器容易求得回归方程

$$\hat{y} = -2.352x + 147.767.$$

(4) 当 $x = 2$ 时, $\hat{y} = 143.063$. 因此, 某天的气温为 2°C 时, 这天大约可以卖出 143 杯热饮.



气温为 2°C 时，小卖部一定能够卖出 143 杯左右热饮吗？为什么？

练习

1. 利用本节例题中求出的回归方程，求当 $x=0$ 时的 y 值，说明它为什么与实际卖出的热饮杯数不一样。
2. 下表给出了某些地区的鸟的种类数与这些地区的海拔高度 (m)，分析这些数据，看一看鸟的种类数与海拔高度是否有关。

地区	A	B	C	D	E	F	G	H	I	J	K
种类数	36	30	37	11	11	13	17	13	29	4	15
海拔/m	1 250	1 158	1 067	457	701	731	610	670	1 493	762	549

阅读



相关关系的强与弱

我们知道，两个变量 x 、 y 正（负）相关时，它们就有相同（反）的变化趋势，即当 x 由小变大时，相应的 y 有由小（大）变大（小）的趋势，因此可以用回归直线来描述这种关系。与此相关的一个问题是：如何描述 x 和 y 之间的这种线性关系的强弱？例如，物理成绩与数学成绩正相关，但数学成绩能够在多大程度上决定物理成绩？这就是相关强弱的问题。类似的还有吸烟与健康的负相关强度、父母身高与子女升高的正相关强度、农作物的产量与施肥量的正相关强度等。

统计中用相关系数 r 来衡量两个变量之间线性关系的强弱。若相应于变量 x 的取值 x_i ，变量 y 的观测值为 y_i ($1 \leq i \leq n$)，则两个变量的相关系数的计算公式为

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

不同的相关性可以从散点图上直观地反映出来。图 1、图 2 反映了变量 x 、 y 之间很强的线性相关关系，而图 4 中的两个变量的线性相关程度很弱。

对于相关系数 r ，首先值得注意的是它的符号。当 r 为正时，表明变量 x 、 y 正相关；

当 r 为负时, 表明变量 x 、 y 负相关, 反映在散点图上, 图 1 中的变量 x 、 y 正相关, 这时的 r 为正, 图 2 中的变量 x 、 y 负相关, 这时的 r 为负。

另一个值得注意的是 r 的大小。统计学认为, 对于变量 x 、 y , 如果 $r \in [-1, -0.75]$, 那么负相关很强; 如果 $r \in [0.75, 1]$, 那么正相关很强; 如果 $r \in (-0.75, -0.30]$ 或 $r \in [0.30, 0.75]$, 那么相关性一般; 如果 $r \in [-0.25, 0.25]$, 那么相关性较弱。反映在散点图上, 图 1 的 $r=0.97$, 这些点有明显的从左下角到右上角沿直线分布趋势, 这时用线性回归模型描述两个变量之间的关系效果很好; 图 2 的 $r=-0.85$, 这些点也有明显的从左上角到右下角沿直线分布趋势, 这时用线性回归模型描述两个变量之间的关系也有好的效果; 图 3 的 $r=0.24$, 这些点的分布几乎没有什么规则, 这时不能用线性回归模型描述两个变量之间的关系; 图 4 的 $r=-0.05$, 两个变量之间几乎没有什么关系, 这时就更不能用线性回归模型描述两个变量之间的关系。

你能试着对自己身边的某个问题, 确定两个变量, 通过收集数据, 计算相关系数, 然后分析一下能否用线性回归模型来拟合它们之间的关系吗?




图 1




图 2




图 3




图 4

习题 2.3

A 组

1. “名师出高徒”可以解释为教师的水平越高,学生的水平也越高.那么,教师的水平与学生的水平成什么相关关系?你能举出更多的描述生活中两个变量的相关关系的成语吗?
2. 有时候,一些东西吃起来口味越好,对我们的身体越有害.下表给出了不同类型的某种食品的数据.第一列表示此种食品所含热量的百分比,第二列数据表示由一些美食家以百分制给出的对此种食品口味的评价:

品牌	所含热量的百分比	口味纪录
A	25	89
B	34	89
C	20	80
D	19	78
E	26	75
F	20	71
G	19	65
H	24	62
I	19	60
J	13	52

- (1) 作出这些数据的散点图.
- (2) 作出回归直线.
- (3) 关于两个变量之间的关系,你能得出什么结论?
- (4) 对于这种食品,为什么人们更喜欢吃位于回归直线上方的食品而不是下方的?
3. 一个车间为了规定工时定额,需要确定加工零件所花费的时间,为此进行了 10 次试验,收集数据如下:

零件数 x (个)	10	20	30	40	50	60	70	80	90	100
加工时间 y (min)	62	68	75	81	89	95	102	108	115	122

- (1) 画出散点图;
- (2) 求回归方程;
- (3) 关于加工零件的个数与加工时间,你能得出什么结论?
4. 影响消费水平的原因是很多的,其中重要的一项是工资收入.研究这两个变量的关系的一个方法是通过随机抽样的方法,在全国范围内收集被调查者的工资收入和他们的消费状况.下面的数据来自国家统计局公布的统计年鉴(2000 年版),是祖国大陆 31 个省、自治区、直辖市的职工平均工资与居民消费水平(单位:元).

省、区、市	北京	天津	河北	山西	内蒙古	辽宁	吉林	黑龙江
职工平均工资	14 054	11 056	7 022	6 065	6 342	7 895	7 158	7 094
居民消费水平	7 040	7 346	5 033	3 932	3 765	6 366	5 216	5 632

续表

省、区、市	上海	江苏	浙江	安徽	福建	江西	山东	河南
职工平均工资	16 641	9 171	11 201	6 516	9 490	6 749	7 656	6 494
居民消费水平	11 943	6 239	7 985	4 985	6 255	3 482	6 060	4 214

续表

省、区、市	湖北	湖南	广东	广西	海南	重庆	四川	贵州
职工平均工资	6 991	9 269	12 245	6 776	6 865	7 182	7 249	6 595
居民消费水平	5 292	5 290	8 987	4 987	4 700	6 190	4 876	4 334

续表

省、区、市	云南	西藏	陕西	甘肃	青海	宁夏	新疆
职工平均工资	8 276	12 962	6 931	7 427	9 081	7 392	7 611
居民消费水平	4 933	4 685	4 520	4 615	4 384	3 813	3 988

- (1) 画出散点图；
- (2) 求出回归方程；
- (3) 从回归方程你能得出一些什么结论？

B 组

1. 有人收集了 10 年中某城市的居民年收入（即此城市所有居民在一年内的收入的总和）与某种商品的销售额的有关数据：

第 n 年	1	2	3	4	5	6	7	8	9	10
年收入/亿元	32.2	31.1	32.9	35.8	37.1	38.0	39.0	43.0	44.6	46.0
商品销售额/万元	25.0	30.0	34.0	37.0	39.0	41.0	42.0	44.0	48.0	51.0

- (1) 画出散点图；
- (2) 求出回归方程；
- (3) 如果这座城市居民的年收入达到 40 亿元，估计这种商品的销售额是多少。
2. 生活中有许多变量之间的关系是值得我们去研究的。例如，关于我们自己的身体、身高与体重之间是否存在某种相关性呢？请从你自己的班里抽取适当的样本，然后再收集好数据，对它们的相关性进行讨论。



现实世界的许多问题中都存在相互关联的各种变量，研究这些变量之间的相互关系，能够使我们发现事物发展的一些规律，从而为我们的判断和决策提供依据。下面请同学们根据自己对身边事物的观察和体会，通过查阅资料、讨论等方式，确定要研究的统计问题，然后进行抽样调查，收集数据，并进行整理和分析，最后对问题中的规律作出判断。确定研究问题时，要注意问题的意义。

以下几个问题，供同学们参考。

1. 在校中学生每周使用计算机时间的调查。

(1) 要调查的问题是什么？

(2) 如何设计抽样方案？

(3) 如何分析数据？

(4) 从中能够得出什么规律？

(5) 你能给同学们提出哪些建议？

2. 中学生物理成绩与数学成绩之间的相关关系。

(1) 要研究的问题是什么？

(2) 如何设计抽样方案？

(3) 如何分析数据？

(4) 从中能够得出什么规律？

(5) 你能给同学们提出哪些建议？

下页的“实习报告”供参考。

实 习 报 告

年 月 日

题目 从中体会样本频率分布 本校学生每周使用计算机时间的调查

抽样方法

年 级	男 生	女 生
一年级		
二年级		
三年级		

样本数据

(单位: min)

频率分布表和
频率分布直方图


计算结果

男生 $\bar{x}_1 = \underline{\hspace{2cm}}$, $s_1 = \underline{\hspace{2cm}}$;
女生 $\bar{x}_2 = \underline{\hspace{2cm}}$, $s_2 = \underline{\hspace{2cm}}$;
男女生全体 $\bar{x} = \underline{\hspace{2cm}}$.

结果分析与建议

小结

一、本章知识结构



二、回顾与思考

1. 统计与现实生活的联系非常密切.

对于现实中的一些随机现象，通过收集大量数据，再通过一定的统计分析来发现随机现象中的规律性，这就是统计这门学科的主要任务。因此，我们应当逐步学会从现实生活或其他学科中提出有意义的统计问题。

你能从你自己的学习、生活中提出一些统计问题吗？为什么你认为这些问题是有意义的？

2. 抽样调查是收集数据的主要方式.

(1) 在抽取样本的过程中，考虑的最主要的原则是什么？

(2) 本章介绍的三种随机抽样方法，它们有什么联系与区别？它们各自的特点和适用范围是什么？你能给国家统计局的城乡调查队设计一个调查全国公众当前最关心的十大问题的抽样方案吗？

3. 用样本估计总体是统计的基本思想.

一般有用样本的频率分布估计总体分布，以及用样本的特征数估计总体的特征数两类估计。

(1) 现实生活中的许多总体的分布我们并不知道。例如，全国所有高一学生的身高作为一个总体，它的分布情况我们是无法准确得知的。那么，通过对全国所有高一

年级学生的身高进行随机抽样,获得的样本频率分布与相应的总体分布有差别吗?另外,样本频率分布有没有随机性?请以你们班同学的身高作为一个总体,从中随机抽取20名同学的身高作为样本,作出样本频率分布图,并与其他同学作出的样本频率分布图比较一下,从中体会样本频率分布的随机性.

(2) 样本的数字特征有众数、中位数、平均数以及标准差.

众数、中位数和平均数是三种最常用的数字特征.众数就是样本数据中出现最多的那个值,如果变量是分类变量,那么用众数是很有必要的.例如,对于班委会要做出的一项决定,考察班里同学对它赞成与否就可以使用众数.你能举出日常生活中使用众数的例子吗?

中位数把样本数据分成了相同数目的两部分,其中一部分都比这个数小,另一部分都比这个数大.在什么情况下用中位数比用众数、平均数等好一些?

我们可以把平均数比喻成为样本数据的“重心”.为什么说,如果平均数的大小与中位数大小差不多时,用平均数比用中位数更合适些?

在“去掉一个最高分9.95分,去掉一个最低分8.80分,选手最后得分9.75分”中,用了什么统计策略?

除了知道数据中心外,知道数据是如何散布的也很重要.标准差就是最重要的表示数据离散程度的量,它表明了平均意义下样本个体数据与平均数的偏离程度.

样本平均数与标准差是否具有随机性?你能举个例子说明吗?

4. 分析两个变量之间的关系.

通常要回答诸如“从样本数据看,变量之间有关系吗”“是什么样的关系”“是否能推广到总体中去”等问题.在本章,我们初步介绍了如何根据样本数据散点图确定两个变量之间是否存在相关关系,以及如何通过最小二乘法求出回归直线.

复习参考题

A 组

1. 选择题

为了了解某地参加计算机水平测试的 5 000 名学生的成绩，从中抽取了 200 名学生的成绩进行统计分析。在这个问题中，5 000 名学生成绩的全体是（ ）

- (A) 总体. (B) 个体.
(C) 从总体中抽取的一个样本. (D) 样本的容量.

2. 填空题

- (1) 在已分组的若干数据中，每组的频数是指_____，每组的频率是指_____。
(2) 一个公司共有 N 名员工，下设一些部门，要采用等比例分层抽样的方法从全体员工中抽取样本容量为 n 的样本，已知某部门有 m 名员工，那么从该部门抽取的员工人数是_____。

3. 在 2002 年春季，一家著名的全国性连锁服装店进行了一项关于当年秋季服装流行色的民意调查，调查者通过向顾客发放饮料，并让顾客通过挑选饮料杯上印着的颜色来对自己喜欢的服装颜色“投票”。根据这次调查结果，在某大城市 A，服装颜色的众数是红色，而当年全国服装协会发布的是咖啡色。

- (1) 这个结果是否意味着 A 城市的人比其他地方的人较少倾向于选择咖啡色？
(2) 你认为这两种调查的差异是由什么引起的？

4. 如果调查目的是要确定被调查者的收入水平，请设计一种提问方法。

5. 从一本英语书中随机抽取 100 个句子，数出每个句子中单词数，作出这 100 个数据的频率分布，由此你可以作出什么估计？

6. 在一个文艺比赛中，12 名专业人士和 12 名观众代表各组成一个评判小组，给参赛选手打分。下面是两个评判组对同一名选手的打分：

小组 A 42 45 48 46 52 47 49 55 42 51 47 45

小组 B 55 36 70 66 75 49 46 68 42 62 58 47

- (1) 解释如何衡量每一组成员的相似性。
(2) 对每一组计算这种相似性的度量值。你能据此判断小组 A 与小组 B 哪一个更像是由专业人士组成的吗？

7. 16 种食品所含的热量值如下：

111 123 123 164 430 190 175 236

430 320 250 280 160 150 210 123

- (1) 求数据的中位数与平均数；
(2) 用这两种数字特征中的哪一种来描述这个数据集更合适？

8. 改革开放以来,我国高等教育事业有了迅速发展.这里我们得到了某省从1990~2000年18~24岁的青年人每年考入大学的百分比.我们把农村、城镇和城市分开统计.为了便于计算,把1990年编号为0,1991年编号为1……2000年编号为10.如果把每年考入大学的百分比作为因变量,把年份从0到10作为自变量进行回归分析,可得到下面三条回归直线:

$$\text{城市 } \hat{y} = 9.50 + 2.84x;$$

$$\text{城镇 } \hat{y} = 6.76 + 2.32x;$$

$$\text{农村 } \hat{y} = 1.80 + 0.42x.$$

- (1) 在同一个坐标系内作出三条回归直线.
- (2) 对于农村青年来讲,系数等于0.42意味着什么?
- (3) 在这一阶段,三个组哪一个的大学入学率年增长最快?
- (4) 请查阅我国人口分布的有关资料,选择一个在高等教育发展上有代表性的省,以这个省的大学入学率作为样本,说明我国在1991~2000年10年间大学入学率的总体发展情况.



1. 在一家保险公司的董事会上,董事们就我国加入世界贸易组织(WTO)后公司的发展战略问题展开激烈讨论,其中一个议题是如何借鉴国外保险公司先进的管理经验,改进公司的管理模式.会议决定对推销员实行目标管理,即给推销员确定一个具体的销售目标.这个销售目标确定的是否合适,直接影响公司的经济效益.如果目标过高,多数推销员完不成任务,会使推销员失去信心;如果目标定得太低,将不利于挖掘推销员的工作潜力.下面一组数据是部分推销员的月销售额(单位:千元):

19.58	16.11	16.45	20.45	20.24	21.66	22.45	18.22	12.34
19.35	20.55	17.45	18.78	17.96	19.91	18.12	14.65	14.78
16.78	18.78	18.29	18.51	17.86	19.58	19.21	18.55	16.34
15.54	17.55	14.89	18.94	17.43	17.14	18.02	19.98	17.88
17.32	19.35	15.45	19.58	13.45	21.34	14.00	18.42	23.00
17.52	18.51	17.16	24.56	25.14				

请根据这组样本数据提出使75%的职工能够完成销售指标的建议.

2. 想像一下一个人从出生到死亡,在每个生日都测量身高,并作出这些数据散点图,这些点将不会落在一条直线上.但在一段时间内的增长数据有时可以用线性回归来分析.下表是一位母亲给儿子作的成长记录:

年龄/周岁	3	4	5	6	7	8	9	10
身高/cm	90.8	97.6	104.2	110.9	115.6	122.0	128.5	134.2

续表

年龄/周岁	11	12	13	14	15	16
身高/cm	140.8	147.6	154.2	160.9	167.6	173.0

- (1) 作出这些数据的散点图.
- (2) 求出这些数据的回归方程.
- (3) 对于这个例子, 你如何解释回归系数的含义?
- (4) 用下一年的身高减去当年的身高, 计算他每年身高的增长数, 并计算他从 3~16 岁身高的年均增长数.
- (5) 解释一下回归系数与每年平均增长的身高之间的联系.

附表

随 机 数 表

03 47 43 73 86	36 96 47 36 61	46 98 63 71 62	33 26 16 80 45	60 11 14 10 95
97 74 24 67 62	42 81 14 57 20	42 53 32 37 32	27 07 36 07 51	24 51 79 89 73
16 76 62 27 66	56 50 26 71 07	32 90 79 78 53	13 55 38 58 59	88 97 54 14 10
12 56 85 99 26	96 96 68 27 31	05 03 72 93 15	57 12 10 14 21	88 26 49 81 76
55 59 56 35 64	38 54 82 46 22	31 62 43 09 90	06 18 44 32 53	23 83 01 30 30
16 22 77 94 39	49 54 43 54 82	17 37 93 23 78	87 35 20 96 43	84 26 34 91 64
84 42 17 53 31	57 24 55 06 88	77 04 74 47 67	21 76 33 50 25	83 92 12 06 76
63 01 63 78 59	16 95 55 67 19	98 10 50 71 75	12 86 73 58 07	44 39 52 38 79
33 21 12 34 29	78 64 56 07 82	52 42 07 44 38	15 51 00 13 42	99 66 02 79 54
57 60 86 32 44	09 47 27 96 54	49 17 46 09 62	90 52 84 77 27	08 02 73 43 28
18 18 07 92 45	44 17 16 58 09	79 83 86 19 62	06 76 50 03 10	55 23 64 05 05
26 62 38 97 75	84 16 07 44 99	83 11 46 32 24	20 14 85 88 45	10 93 72 88 71
23 42 40 64 74	82 97 77 77 81	07 45 32 14 08	32 98 94 07 72	93 85 79 10 75
52 36 28 19 95	50 92 26 11 97	00 56 76 31 38	80 22 02 53 53	86 60 42 04 53
37 85 94 35 12	83 39 50 08 30	42 34 07 96 88	54 42 06 87 98	35 85 29 48 39
70 29 17 12 13	40 33 20 38 26	13 89 51 03 74	17 76 37 13 04	07 74 21 19 30
56 62 18 37 35	96 83 50 87 75	97 12 55 93 47	70 33 24 03 54	97 77 46 44 80
99 49 57 22 77	88 42 95 45 72	16 64 36 16 00	04 43 18 66 79	94 77 24 21 90
16 08 15 04 72	33 27 14 34 09	45 59 34 68 49	12 72 07 34 45	99 27 72 95 14
31 16 93 32 43	50 27 89 87 19	20 15 37 00 49	52 85 66 60 44	38 68 88 11 80
68 34 30 13 70	55 74 30 77 40	44 22 78 84 26	04 33 46 09 52	68 07 97 06 57
74 57 25 65 76	59 29 97 68 60	71 91 38 67 54	13 58 18 24 76	15 54 55 95 52
27 42 37 86 53	48 55 90 65 72	96 57 69 36 10	96 46 92 42 45	97 60 49 04 91
00 39 68 29 61	66 37 32 20 30	77 84 57 03 29	10 45 65 04 26	11 04 96 67 24
29 94 98 94 24	68 49 69 10 82	53 75 91 93 30	34 25 20 57 27	40 48 73 51 92
16 90 82 66 59	83 62 64 11 12	67 19 00 71 74	60 47 21 29 68	02 02 37 03 31
11 27 94 75 06	06 09 19 74 66	02 94 37 34 02	76 70 90 30 86	38 45 94 30 38
35 24 10 16 20	33 32 51 26 38	79 78 45 04 91	16 92 53 56 16	02 75 50 95 98
38 23 16 86 38	42 38 97 01 50	87 75 66 81 41	40 01 74 91 62	48 51 84 08 32
31 96 25 91 47	96 44 33 49 13	34 86 82 53 91	00 52 43 48 85	27 55 26 89 62
66 67 40 67 14	64 05 71 95 86	11 05 65 09 68	76 83 20 37 90	57 16 00 11 66
14 90 84 45 11	75 73 88 05 90	52 27 41 14 86	22 98 12 22 08	07 52 74 95 80
68 05 51 18 00	33 96 02 75 19	07 60 62 93 55	59 33 82 43 90	49 37 38 44 59

20 46 78 73 90	97 51 40 14 02	04 02 33 31 08	39 54 16 49 36	47 95 93 13 30
64 19 58 97 79	15 06 15 93 20	01 90 10 75 06	40 78 78 89 62	02 67 74 17 33
05 26 93 70 60	22 35 85 15 13	92 03 51 59 77	59 56 78 06 83	52 91 05 70 74
07 97 10 88 23	09 98 42 99 64	61 71 62 99 15	06 51 29 16 93	58 05 77 09 51
68 71 86 85 85	54 87 66 47 54	73 32 08 11 12	44 95 92 63 16	29 56 24 29 48
26 99 61 65 53	58 37 78 80 70	42 10 50 67 42	32 17 55 85 74	94 44 67 16 94
14 65 52 68 75	87 59 36 22 41	26 78 63 06 55	13 08 27 01 50	15 29 39 39 43
17 53 77 58 71	71 41 61 50 72	12 41 94 96 26	44 95 27 36 99	02 96 74 30 83
90 26 59 21 19	23 52 23 33 12	96 93 02 18 39	07 02 18 36 07	25 99 32 70 23
41 23 52 55 99	31 04 49 69 96	10 47 48 45 88	13 41 43 89 20	97 17 14 49 17
60 20 50 81 69	31 99 73 68 68	35 81 33 03 76	24 30 12 48 60	18 99 10 72 34
91 25 38 05 90	94 58 28 41 36	45 37 59 03 09	90 35 57 29 12	82 62 54 65 60
34 50 57 74 37	98 80 33 00 91	09 77 93 19 82	74 94 80 04 04	45 07 31 66 49
85 22 04 39 43	73 81 53 94 79	33 62 46 86 28	08 31 54 46 31	53 94 13 38 47
09 79 13 77 48	73 82 97 22 21	05 03 27 24 83	72 89 44 05 60	35 80 39 94 88
88 75 80 18 14	22 95 75 42 49	39 32 83 22 49	02 48 07 70 37	16 04 61 67 87
90 96 23 70 00	39 00 03 06 90	55 85 78 38 36	94 37 30 69 32	90 89 00 76 33
53 74 23 99 67	61 32 28 69 84	94 62 67 86 24	98 33 41 19 95	47 53 53 38 09
63 38 06 86 54	99 00 65 26 94	02 82 90 23 07	79 62 67 80 60	75 91 12 81 19
35 30 58 21 46	06 72 17 10 94	25 21 31 75 96	49 28 24 00 49	55 65 79 78 07
63 43 36 82 69	65 51 18 37 88	61 38 44 12 45	32 92 85 88 65	54 34 81 85 35
98 25 37 55 26	01 91 82 81 46	74 71 12 94 97	24 02 71 37 07	03 92 18 66 75
02 63 21 17 69	71 50 80 89 56	38 15 70 11 48	43 40 45 86 98	00 83 26 91 03
64 55 22 21 82	43 22 28 06 00	61 54 13 43 91	82 78 12 23 29	06 66 24 12 27
85 07 26 13 89	01 10 07 82 04	59 63 69 36 03	69 11 15 83 80	13 29 54 19 28
58 54 16 24 15	51 54 44 82 00	62 61 65 04 69	38 18 65 18 97	85 72 13 49 21
34 85 27 84 87	61 48 64 56 26	90 18 48 13 26	37 70 15 42 57	65 65 80 39 07
03 92 18 27 46	57 99 16 96 56	30 33 72 85 22	84 64 38 56 98	99 01 30 93 64
62 93 30 27 59	37 75 41 66 48	86 97 80 61 45	23 53 04 01 63	45 76 08 64 27
08 45 93 15 22	60 21 75 46 91	93 77 27 85 42	28 88 61 08 84	69 62 08 42 78
07 08 55 18 40	45 44 75 13 90	24 94 96 61 02	57 55 66 83 15	73 42 37 11 61
01 85 89 95 66	51 10 19 34 88	15 84 97 19 75	12 76 39 43 78	64 63 91 08 25
72 84 71 14 85	19 11 58 49 26	50 11 17 17 76	86 81 57 20 18	95 60 78 46 75
88 78 28 16 84	13 52 58 94 53	75 45 69 80 96	73 89 65 70 31	99 17 48 48 76
45 17 75 65 57	28 40 19 72 12	25 12 74 75 67	60 40 60 81 19	24 62 01 61 16

96 76 28 12 54	22 01 11 94 25	71 96 16 16 88	68 64 36 74 45	19 59 50 88 92
43 31 67 72 30	24 02 94 08 63	88 32 36 66 02	69 36 88 25 39	48 08 45 15 22
50 44 66 44 21	66 06 58 05 62	68 15 54 35 02	42 35 48 96 32	14 52 41 52 48
22 66 22 15 86	26 63 75 41 99	58 42 36 72 24	58 37 52 18 51	03 37 18 39 11
96 24 40 14 51	28 22 30 88 57	95 67 47 29 88	94 69 40 06 07	18 16 36 78 86
31 73 91 61 19	60 20 72 98 48	98 57 07 28 69	65 95 39 69 58	56 80 30 19 44
78 60 73 99 84	43 89 94 36 45	56 69 47 07 41	90 22 91 07 12	78 35 34 08 72
84 37 90 61 56	70 10 23 98 05	85 11 34 76 60	76 48 45 34 60	01 64 18 39 96
36 67 10 08 23	98 93 35 08 86	99 29 76 29 81	88 34 91 58 93	63 14 52 32 52
07 28 59 07 48	89 64 58 89 75	83 85 62 27 89	30 14 78 56 27	86 63 59 80 02
10 15 83 87 60	79 24 31 66 56	21 48 24 06 93	91 98 94 05 49	01 47 59 38 00
55 19 68 97 65	03 73 52 16 56	00 58 55 90 27	33 42 29 38 87	22 13 88 83 34
53 81 29 13 39	35 01 20 71 34	62 33 74 82 14	53 73 19 09 03	56 54 29 56 93
51 86 32 68 92	33 98 74 66 99	40 14 71 94 58	45 94 19 33 81	14 44 99 81 07
35 91 70 29 13	80 03 54 07 27	96 94 78 32 66	50 95 52 74 33	13 80 55 62 54
37 71 67 95 13	20 02 44 95 94	64 85 04 05 72	01 32 90 76 14	53 89 74 60 41
93 66 13 83 27	92 79 64 64 72	28 54 96 53 84	48 14 52 98 94	56 07 93 39 30
02 96 08 45 65	13 05 00 41 84	93 07 54 72 59	21 45 57 09 77	19 48 56 27 44
49 83 43 48 35	82 88 33 69 96	72 36 04 19 76	47 45 15 18 60	82 11 08 95 97
84 60 71 62 46	40 80 81 30 37	34 39 23 05 33	25 15 35 71 30	88 12 57 21 77
18 17 30 88 71	44 91 14 88 47	89 23 30 63 15	56 34 20 47 89	99 82 93 24 93
79 69 10 61 78	71 32 76 95 62	87 00 22 58 40	92 54 01 75 25	43 11 71 99 31
75 93 36 57 83	56 20 14 82 11	74 21 97 90 65	98 42 68 63 86	74 54 13 26 94
38 30 92 29 03	06 23 81 39 38	62 25 06 84 63	61 29 08 93 67	04 32 92 08 09
51 29 50 10 34	31 57 75 95 80	51 97 02 74 77	76 15 48 49 44	18 55 63 77 09
21 31 38 86 24	37 79 81 53 74	73 24 16 10 33	52 83 90 94 76	70 47 14 54 36
29 01 23 87 83	58 02 39 37 67	42 10 14 20 92	16 55 23 42 45	54 96 09 11 06
95 33 95 22 00	18 74 72 00 18	38 79 58 69 32	81 76 80 26 92	82 80 84 25 39
90 84 60 79 80	24 36 59 87 38	82 07 53 89 35	96 35 23 79 18	05 98 90 07 35
46 40 62 98 80	54 97 20 56 95	15 74 80 08 32	16 46 70 50 80	67 72 16 42 79
20 31 89 03 43	38 46 82 68 72	32 14 82 99 70	80 60 47 18 97	63 49 30 21 30
71 59 73 05 50	08 22 23 71 77	91 01 93 20 49	82 96 59 26 94	66 39 67 98 60